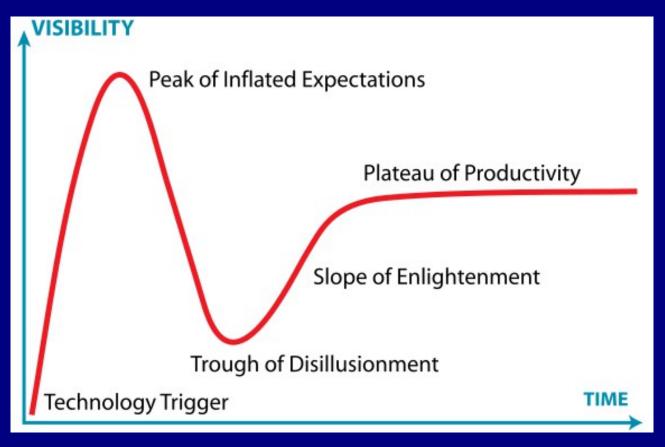
NoSQL & Big Data

Stanowiska względem baz NoSQL

 Opinie na temat rodziny technologii NoSQL są mocno spolaryzowane:

- Wielbiciele
- wykorzystują aktywnie, testują, wdrażają
- Przeciwnicy
- skupiają się na słabościach i niedoskonałościach
- Sceptycy
- ignorują, czekają na ustabilizowanie technologii...

"Hype Cycle"



Źródło: http://en.wikipedia.org/wiki/Hype_cycle

Definicja baz NoSQL

- Literalnie No SQL, w praktyce powinno być raczej No RDBMS (był nawet pomysł by było to NonRel), ogółem zbiór technologii bazodanowych, które starają się mierzyć z czterema współczesnymi problemami przy przetwarzaniu danych (Volume, Velocity, Variability, Agility).
- Bazy nierelacyjne istnieją od lat (a nawet istniały przed bazami relacyjnymi), ich aktualny rozwój jest ściśle powiązany z rozwojem Internetu i problemami jakie pojawiły się przy przetwarzaniu gigantycznych ilości danych jakie wraz z nim zaczęły się pojawiać, w założeniu mają pokonywać ograniczenia modelu relacyjnego.
- W przypadku gigantycznych zbiorów danych skalowalność baz relacyjnych zaczyna być problemem. Trudno w ich wypadku stosować skalowanie poziome (ang. *horizontal*) a preferowane skalowanie pionowe (ang. *vertical*) jest kosztowne.
- Więcej informacji na temat definicji tutaj: http://nosql-database.org/

Ograniczenia modelu relacyjnego

- Z góry określona struktura danych, którą modelujemy na samym początku.
- Dane są kompletne, powiązania między danymi nie ulegają istotnym zmianom, z góry określamy indeksy, które optymalizują nam wyszukiwanie potrzebnych informacji.
- Model nie skaluje się aż tak dobrze, w przypadku "Big Data" zaczynają się pojawiać problemy.
- Można częściowo pokonywać te ograniczenia, ale w istocie jest to odejście od modelu relacyjnego: http://backchannel.org/blog/friendfeed-schemaless-mysql

Podejścia do skalowalności

• Scaling-up – skalowalność pionowa, zwiększanie mocy obliczeniowej przez rozbudowę pojedynczej maszyny, relatywnie prosta, ale od pewnego momentu (skali) bardzo kosztowna.

• Scaling-out – skalowalność pozioma, zwiększenie mocy obliczeniowej przed dodawanie kolejnych maszyn (przetwarzanie równoległe/rozproszone), komplikuje projekt i implementację, ale daje praktycznie nieograniczone możliwości rozbudowy.

Przetwarzanie danych i Big Data

- Pojęcie "Big Data" może być interpretowane różnie, jedno z bardziej racjonalnych określeń, to stwierdzenie, że mamy z nim do czynienia, jeżeli ilość danych do przetworzenia przekracza możliwości pojedynczej maszyny.
- Mniej więcej taką definicję można znaleźć na Wikipedii: http://en.wikipedia.org/wiki/Big_data
- Ciekawa jest wizja przyszłości jeżeli chodzi o ilość przetwarzanych danych, która jest prezentowana w
 "The Digital Universe Decade Are you ready?": http://www.emc.com/collateral/demos/microsites/emc-digital-universe-2011/index.htm
- Ale są też głosy, że całe to pojęcie to tylko chwilowa fanaberia i marketing: http://www.simple-talk.com/sql/database-administration/big-data-is-just-a-fad/

Podejście wykorzystujące bazy NoSQL

• Można tu mówić o częściowym pokonywaniu ograniczeń modelu relacyjnego, ale, dzieje się to kosztem:

• braku lub ograniczenia wsparcia dla transakcji i mechanizmów sprawdzających spójność danych

utrudnieniem odpytywania o potrzebne informacje

• nieco mniej elastycznym podejściem do indeksowania

Geneza baz NoSQL

- Google
 - 2003 "The Google File System": http://research.google.com/archive/gfs.html
 - 2004 "MapReduce: Simplified Data Processing on Large Clusters" http://research.google.com/archive/mapreduce.html
 - 2006 "Bigtable: A Distributed Storage System for Structured Data" http://research.google.com/archive/bigtable.html
 - 2006 "The Chubby lock service for loosely-coupled distributed systems"
 http://static.googleusercontent.com/external content/untrusted dlcp/research.goog
- Amazon
 - 2007 "Amazon's Dynamo" http://www.allthingsdistributed.com/2007/10/amazons dynamo.html

Bazy NoSQL i wsparcie dla Big Data

 Poprzez zapewnienie efektywnego przechowywania i pobierania gigantycznych ilości danych, zapewniając dużą odporność na awarie.

 Wykorzystanie przetwarzania równoległego, możliwie największą skalowalność, pożądane jest uzyskanie stałego czasu odpowiedzi przy zmiennym obciążeniu.

• Wsparcie dla przechowywania i przetwarzania danych, których struktura nie jest z góry określona i może się znacząco zmieniać w czasie.

MapReduce

 Opatentowany przez Google model programowania równoległego wykorzystywanego do przetwarzania ogromnych zbiorów danych z wykorzystaniem klastrów komputerów.

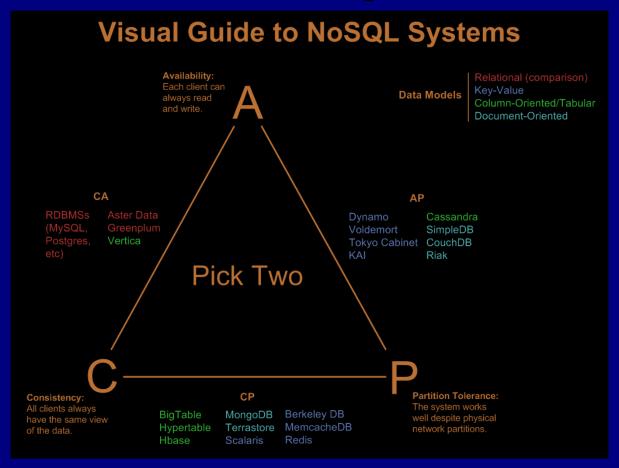
• Źródłem jest programowanie funkcjonalne w którym występują pojęcia funkcji map i reduce (fold): http://en.wikipedia.org/wiki/MapReduce

 Powyższe podejście stało się inspiracją dla wielu projektów Open Source i w efekcie baz NoSQL.

CAP Theorem i BASE

- <u>CAP Theorem</u> teoria zgodnie z którą nie możemy w systemie rozproszonym uzyskać jednocześnie: spójności (ang. *consistency*), dostępności (ang. *availability*) i tolerancji dla partycji (ang. *partition tollerance*).
- BASE (ang. Basically Available, Soft state, Eventual consistency) alternatywa dla modelu ACID, oferująca "ewentualną" spójność.
- I jedno i drugie jest bardzo ważne w kontekście rozwiązań NoSQL.
- Ciekawa prezentacja na ten temat: http://www.slideshare.net/larsga/nosql-databases-the-cap-theorem-ai/

CAP Theorem i bazy NoSQL



Źródło: http://blog.nahurst.com/visual-guide-to-nosql-systems

Klasyfikacja baz NoSQL

- "Bazy kolumnowe" (ang. sorted ordered column-oriented stores):
 - HBase, Hypertable, Cloudata
- "Bazy klucz-wartość" (ang. key/value stores):
 - Oracle Berkeley DB, EHCache, Memcached, Membase, Kyoto Cabinet, Redis, Cassandra, Voldemort, Riak
- "Bazy dokumentowe" (ang. *document databases*):
 - MongoDB, CouchDB
- "Bazy grafowe" (ang. *graph databases*):
 - Neo4j, FlockDB
- Bazy obiektowe (ang. object databases):
 - Versant Object Database, db40
- <u>Bazy XML</u> (ang. *xml databases*):
 - BaseX, eXist
- Powyższe jest dość luźną klasyfikacją, gdyż definicja NoSQL jest zbyt mało precyzyjna, nieco inną klasyfikację można znaleźć np. tutaj: http://en.wikipedia.org/wiki/NoSQL
- Bardziej wyczerpująca lista produktów klasyfikowanych jako NoSQL może zostać odnaleziona w tym miejscu: http://nosql-database.org/

"Bazy kolumnowe"

- Definicja: http://en.wikipedia.org/wiki/Column-oriented_DBMS
- Przechowywanie danych w kolumnach nie w wierszach.
- Efektywne wykorzystanie przestrzeni dyskowej, szybkie pobieranie danych.
- Nieco więcej o zaletach:
 - http://
 horicky.blogspot.com/2010/10/bigtable-model-with-cassandra-

HBase (Apache Hadoop)

- http://hbase.apache.org/
- http://hadoop.apache.org/



- http://radar.oreilly.com/2012/01/microsoft-big-data.html
- Wykorzystujący:
 - http://wiki.apache.org/hadoop/PoweredBy
 - Amazon, EBay, Facebook, ...
- Instalacja:
 - http://alans.se/blog/2010/hadoop-hbase-cygwin-windows-7-x64/

"Bazy klucz-wartość"

- Prezentacja: <a href="http://www.slideshare.net/marc.seeger/keyvalue-stores-a-practical-overview-stores-a-practical-over-a-practical-over-a-practical-over-a-
- Można je porównać do prostych tablic haszowanych, mamy klucz poprzez który odwołujemy się do konkretnej wartości.
- Potencjalnie najbardziej skalowalne.
- Bardzo prosty (w efekcie ograniczony) model danych.
- Ciekawy dokumentach o tego rodzaju bazach:
 https://www.simple-talk.com/cloud/data-science/data-science-labor/

Cassandra

- http://cassandra.apache.org/
- Wykorzystujący:
 - http://www.datastax.com/cassandrausers
 - Facebook, Twitter, Cisco Webex, Digg, ...
- Instalacja:
 - <a href="http://coderjournal.com/2010/03/cassandra-jump-start-for-the-windows-de-language-to-the-win

Cassandra

- Programowanie:
 - http://www.ridgway.co.za/archive/2009/11/06/net-developers-guide-to-getting-stare

"Bazy dokumentowe"

- Definicja: http://en.wikipedia.org/wiki/Document-oriented database
- Pozwalają na przechowywanie "dokumentów" o praktycznie dowolnej strukturze.
- Ciekawy opis pracy z bazami dokumentowymi:
 <a href="https://www.simple-talk.com/cloud/data-science/da

MongoDB

- http://www.mongodb.org/
- Wykorzystujący:



- SAP, SourceForge, MTV Networks, ...
- Instalacja:
 - http://www.mongodb.org/display/DOCS/Quickstart+Windows
- Programowanie:
 - http://www.mongodb.org/display/DOCS/CSharp+Driver+Tutorial



"Bazy grafowe"

- Definicja: http://en.wikipedia.org/wiki/Graph database
- Główni gracze: http://www.readwriteweb.com/cloud/2011/04/5-graph-databases-tem-
- Umożliwiają reprezentacje danych, których modelowanie w bazach relacyjnych jest utrudnione.
- Ciekawy dokument o bazach grafowych:
 https://www.simple-talk.com/cloud/cloud-data/data-science
 E2%80%93-graph-databases/

Neo4j



- http://neo4j.org/
- http://www.slideshare.net/peterneubauer/neo4j-5-cool-graph-examples-4473985
- http://highscalability.com/neo4j-graph-database-kicks-buttox
- Wykorzystujący:
 - http://neotechnology.com/customers/
 - Adobe, Cisco, ...
- Instalacja:
 - http://docs.neo4j.org/chunked/1.4/server-installation.html
- Programowanie:
- http://blog.jayway.com/2010/04/16/ne04j-net-client-over-http-using-rest-and-json/l/

Bazy obiektowe

- Definicja: http://en.wikipedia.org/wiki/Object database
- Obchodzą ograniczenie modelu relacyjnego pozwalając wprost przechowywać w bazie danych obiekty aplikacji.

Db40

http://www.db4o.com/



- Wykorzystanie:
 - http://www.db4o.com/about/customers/success/
 - Seagate, Postbank, ...
- Instalacja:
 - http://www.emphess.net/2010/01/23/a-simple-standalone-server-
- Programowanie:
 - http://tutorial.fyicenter.com/out.php?ID=2339

Bazy XML

- Definicja: http://en.wikipedia.org/wiki/XML database
- Wykorzystują język XML i technologie pokrewne (XPath, XQuery, XSTL) do przechowywania i przetwarzania danych.

BaseX

http://basex.org/

BASE

- Wykorzystanie:
 - http://basex.org/customers/
 - Airbus, Max Planck Institute, ...
- Instalacja:
 - http://docs.basex.org/wiki/Startup
- Programowanie:
 - http://docs.basex.org/wiki/Java Examples

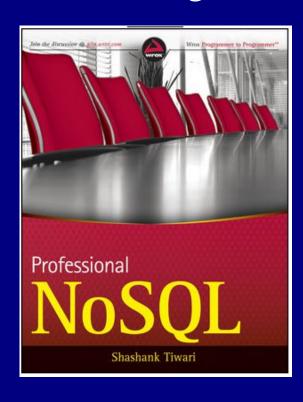
Problemy z bazami NoSQL

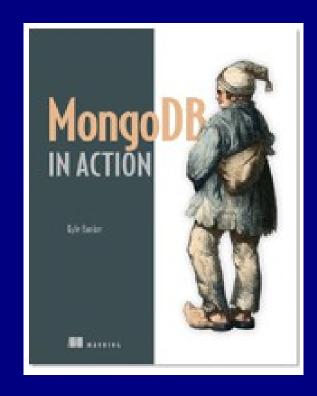
- Brak standardów: tak co do modelu danych jak i języka wykorzystywanego do typowych operacji CRUD.
- Olbrzymi wybór, ale brak zdecydowanych faworytów.
- Technologia nowa, ciągle jeszcze mało ustabilizowana.
- Małe grono osób znających bazy NoSQL (po części konsekwencja ich różnorodności i braku standardów).
- Wspomniane wcześniej ograniczenia dotyczące kwestii transakcji, odpytywania, indeksów, w przypadku gdy potrzebujemy tych elementów bazy relacyjne są ciągle najlepszym wyborem.
- Problematyczne podejście do kwestii bezpieczeństwa (a w dużej mierze jego brak*):
 http://

www.darkreading.com/database-security/167901020/security/news/232400214/d

Do poczytania:

- S. Tiwari, "Professional NoSQL"
- K. Banker, "MongoDB in Action"





Do obejrzenia:

• M. Fowler, "Introduction to NoSQL"